

PROFESSOR: Eduardo Savino Gomes	
CURSO: Ciência da Computação	
DISCIPLINA: Projeto Interdisciplinar Ciência de Dados	
TURMA: Noturno	DATA: 25/09
ALUNO(A): Bruno Rodrigues Da Costa, Guilherme Monteiro Da Silva, João Pedro Da Silva, Stefany Samira De Oliveira Cubertino	

1. Identificação das Fontes de Dados

O conjunto de dados utilizado neste projeto foi disponibilizado pela CTI Global, empresa parceira do Projeto Interdisciplinar, e representa uma simulação de Monte Carlo do modelo financeiro de uma concessão de infraestrutura.

Item	Descrição
Arquivo	Demonstrativo_Fecap_v3.csv
Origem	Simulação de Monte Carlo, modelo financeiro de concessão de infraestrutura
Granularidade	1.200 cenários x 12 anos x 69 contas financeiras (BAL, DRE, FLU)
Formato	CSV; separador ";"; decimal "."; sem cabeçalho; UTF-8
Volume	1.002.000 linhas em formato longo
Colunas brutas	Ano, Cenário, Conta, Valor
Condição de uso	Dado interno do projeto, fornecido para fins acadêmicos


2. Coleta dos Dados Iniciais

Os dados foram carregados diretamente do arquivo CSV fornecido, em ambiente Google Colab, utilizando a biblioteca pandas. Nenhuma etapa de extração de fontes externas foi necessária, já que a CTI Global disponibilizou o arquivo completo diretamente para a equipe.

Resultado da carga: 1.002.000 linhas, 4 colunas (Ano, Cenário, Conta, Valor).

3. Descrição dos Dados


As colunas brutas chegam como texto (strings), inclusive a coluna Valor, que segue o padrão numérico brasileiro (ponto como separador de milhar e vírgula como separador decimal). A base cobre 12 anos de concessão e 1.200 cenários simulados, com 69 contas financeiras distintas distribuídas entre Balanço Patrimonial (BAL), Demonstração de Resultados (DRE) e Fluxo de Caixa (FLU).



4. Exploração dos Dados

A exploração inicial identificou dois padrões estruturais importantes:

- 43.200 linhas (4,31% do total) têm a coluna Conta vazia, não são contas financeiras, mas sim 3 parâmetros auxiliares da simulação por combinação cenário/ano.
- 27 contas de Balanço Patrimonial deixam de aparecer no Ano 12, investigação com o professor orientador confirmou que isso reflete a liquidação de direitos e obrigações no encerramento da concessão, e não uma falha de coleta.



5. Seleção dos Dados

Nenhum registro foi descartado por qualidade. Os 1.002.000 registros brutos foram integralmente aproveitados, divididos em duas tabelas com finalidades distintas:

- Base de contas financeiras (958.800 linhas): as 69 contas de BAL, DRE e FLU, que formam o núcleo analítico do projeto.
- Base de parâmetros auxiliares (43.200 linhas): os 3 parâmetros por cenário/ano com Conta vazia, mantidos separadamente para não introduzir ruído na base analítica principal.

6. Limpeza e Uniformização dos Dados

Foram aplicadas as seguintes transformações:

- Conversão da coluna Ano (texto "Ano N") para valor inteiro.
- Conversão da coluna Valor do formato numérico brasileiro para float, permitindo cálculos.
- Padronização de sinal: contas do lado do Passivo e do Patrimônio Líquido (ex.: Empréstimos, Passivo Circulante) apresentavam valores ora positivos, ora negativos entre cenários, foram padronizadas para valor absoluto, pois o sinal não é informativo para contas de saldo.
- Confirmação de que os pares de nomes quase idênticos, "Emprést" vs. "Empréstimos" e "Outros deb" vs. "Outros Débitos", são contas distintas: a primeira de cada par é fixa entre cenários (dívida contratual), a segunda varia (valor simulado).

7. Derivação e Integração dos Dados

Derivação: a coluna original DRE - EBITDA diverge do EBITDA recalculado a partir de suas contas-base em 1,6% a 15,6%, dependendo do ano. Por isso, o projeto adota, em todas as análises subsequentes, o EBITDA recalculado:

$$EBITDA = \text{Resultado Operacional} + |\text{Depreciação e Amortização}|$$

Integração: a tabela longa (uma linha por combinação Ano × Cenário × Conta) foi pivotada para o formato wide (uma linha por combinação Ano × Cenário, com uma coluna por conta), resultando em uma base analítica de 14.400 linhas (1.200 cenários × 12 anos) por 72 colunas, pronta para uso pelas demais disciplinas do projeto (Contabilidade e Finanças, Análise Inferencial de Dados, Engenharia de Software).

Validação de integridade: verificamos a identidade contábil Ativo = Passivo + Patrimônio Líquido nos dados agregados. A diferença observada aumenta ao longo dos anos, refletindo o comportamento agregado da simulação de Monte Carlo sobre o modelo financeiro fornecido, e será detalhada com a equipe de Contabilidade e Finanças na próxima entrega.

8. Formatação dos Dados

As 27 contas de Balanço ausentes no Ano 12 foram explicitamente marcadas com o texto "N/D" nas células correspondentes da base final, e não deixadas em branco ou preenchidas com zero. Essa escolha evita que fórmulas de indicadores (ex.: liquidez, endividamento) tratem uma conta inexistente como saldo zerado, o que geraria índices distorcidos.

Arquivos finais gerados por esta entrega:

- base_analitica_cti.csv - base analítica limpa em formato wide (14.400 linhas × 72 colunas), pronta para as demais Unidades Curriculares.
- parametros_auxiliares.csv - parâmetros auxiliares da simulação, separados da base principal.